

RELATÓRIO TÉCNICO

Localização de Facilidades em Goiás: Heurísticas e Modelagem Multiobjetivo

Disciplina: Heurísticas e Modelagem Multiobjetivo

Tema: Problema P4 — Localização de Facilidades em Goiás

Equipe

Christian de Souza Ramos
Igor Garbin Manzan Mazo
Leonardo Lima de Oliveira
Livia Maria Santos Rocha
Maria Eduarda Fernandes de Souza

Junho de 2026

Sumário

1. Introdução	3
2. Formulação do Problema e Dataset	3
3. Metodologia	4
3.1 Algoritmo Genético Binário (Single-Objective)	4
3.2 NSGA-II (Multiobjetivo)	4
4. Resultados Experimentais	5
4.1 Sensibilidade aos Hiperparâmetros	5
4.2 Convergência	5
4.3 Distribuição Espacial da Solução	6
4.4 Comparação Final e Fronteira de Pareto	7
5. Discussão de Trade-offs e Equidade Espacial	8
6. Conclusão	9
6.1 Limitações e Próximos Passos	9
7. Referências	10

1. Introdução

Este relatório apresenta o projeto final da disciplina de Heurísticas e Modelagem Multiobjetivo, referente ao tema P4 — Localização de Facilidades em Goiás: decidir, entre os 246 municípios do estado, onde instalar k facilidades de atendimento, de modo a melhorar o acesso da população a esses serviços.

O problema é intrinsecamente multiobjetivo: minimizar a distância média até a facilidade mais próxima favorece a concentração de unidades nas regiões mais populosas, enquanto maximizar a cobertura e garantir equidade espacial — não deixar municípios periféricos sistematicamente desassistidos — exige distribuir as facilidades de forma mais dispersa. Este documento descreve a formulação matemática, a metodologia (Algoritmo Genético Binário na versão single-objective e NSGA-II na versão multiobjetivo), os experimentos realizados e a discussão dos trade-offs entre eficiência, cobertura e equidade.

2. Formulação do Problema e Dataset

Seja $M = \{1, \dots, n\}$ o conjunto de municípios de Goiás ($n = 246$). Para cada município i , o dataset (`goias_facility_locations.csv`) traz a população p_i (Censo 2022), as coordenadas geográficas e um custo sintético de instalação c_i , calculado a partir de população, área e PIB municipal normalizados. A matriz de distâncias Haversine $d(i,j)$, em km, é pré-computada (`distance_matrix_km.npy`). Os parâmetros globais, em `problem_config.json`, são $k = 12$ facilidades, orçamento $B = \text{R\$ } 20.939.128,69$, população total $P = 7.056.495$ e raio de cobertura $R = 80$ km.

A variável de decisão é binária — $x_i \in \{0,1\}$, indicando se uma facilidade é instalada no município i — representada como um vetor binário de tamanho n , adequado ao Algoritmo Genético Binário. Na versão single-objective, o objetivo é minimizar a distância média ponderada pela população:

$$f(x) = (1/P) \cdot \sum_{i,j} p_i \cdot \min_{i: x_i=1} d(i,j)$$

Na versão multiobjetivo (NSGA-II), três objetivos são otimizados simultaneamente: f_1 (a mesma distância média acima), f_2 (percentual da população não coberta dentro de $R = 80$ km) e f_3 (percentil 95 ponderado das distâncias, métrica de equidade espacial — operacionalizando a preocupação ética do projeto com municípios periféricos). As restrições são C1: exatamente k facilidades instaladas ($\sum x_i = k$) e C2: custo total dentro do orçamento ($\sum c_i x_i \leq B$). No AG single-objective, C1 é garantida por um operador de reparo e C2 por penalização escalar, $f_{\text{pen}}(x) = f(x) + \lambda \cdot \max(0, \text{custo} - B)$, com λ estimado empiricamente pela razão entre a magnitude típica de $f(x)$ e a violação orçamentária típica em 50 soluções aleatórias.

3. Metodologia

3.1 Algoritmo Genético Binário (Single-Objective)

Implementado em `algoritmo.py`: inicialização sorteia exatamente k posições por indivíduo; seleção por torneio ($k=3$); cruzamento de dois pontos seguido de reparo (ajusta o número de uns para k); mutação bit-flip seguida do mesmo reparo; elitismo preserva a melhor solução entre gerações. A avaliação usa $f_{\text{pen}}(x)$ descrita na Seção 2. Cinco configurações de hiperparâmetros foram testadas:

Configuração	pop_size	n_gen	Observação
baseline	100	300	configuração padrão, usada como referência
V1_pop200	200	300	população maior
V2_pop50	50	300	população menor
V3_gen500	100	500	mais gerações
V4_pop200_gen500	200	500	população e gerações maiores

3.2 NSGA-II (Multiobjetivo)

O NSGA-II (DEB et al., 2002) otimiza f_1 , f_2 e f_3 simultaneamente. A restrição orçamentária C2 não é penalizada, mas tratada por dominância restrita: soluções viáveis sempre dominam inviáveis; entre inviáveis, vence a de menor violação; entre viáveis, aplica-se a dominância de Pareto usual. Essa abordagem dispensa calibração de parâmetro e garante, por construção, um front final 100% viável. Os experimentos usaram cinco sementes (42, 123, 456, 789, 1011). Uma métrica complementar de equidade baseada no índice de Gini, aplicada às distâncias mínimas, também foi implementada pela equipe (Christian); seus resultados numéricos ainda não foram consolidados neste relatório.

4. Resultados Experimentais

4.1 Sensibilidade aos Hiperparâmetros




Figura 1 — Distribuição do fitness por configuração (fig1_boxplot.png).




Figura 2 — Fitness médio por configuração, com barras de erro (fig3_barras.png).

A configuração V2_pop50 (população reduzida) tem a maior dispersão e a maior média ($\approx 40,7$ km, $\pm 1,05$), confirmando que populações pequenas tornam a busca instável. V3_gen500 (mais gerações) obtém a menor média ($\approx 39,3$ km), o que motivou sua escolha como referência do AG single-objective na comparação final (Seção 4.4).

4.2 Convergência




Figura 3 — Convergência do fitness da elite: baseline (300 gerações) e V3_gen500 (500 gerações) (fig2_convergencia.png).

O fitness cai rapidamente de $\approx 51,8$ km para ≈ 44 km já na geração 20, estabilizando-se em $\approx 40,1$ – $40,2$ km a partir da geração 250 — as gerações adicionais de V3_gen500 (300 a 500) trazem ganho apenas marginal.

4.3 Distribuição Espacial da Solução




Figura 4 — As 12 facilidades na melhor solução encontrada (V3_gen500, seed 789) (fig4_mapa.png).

As facilidades não se concentram apenas na faixa central, mais densa em municípios (latitudes -16 a -17): há unidades também ao norte (≈ -14), a leste ($\approx -46,3, -14,4$) e ao sul ($\approx -18,2$) — uma dispersão compatível com o equilíbrio entre distância média e cobertura.

4.4 Comparação Final e Fronteira de Pareto

A comparação final, sobre cinco sementes, considera a configuração baseline, a V3 do AG single-objective e o NSGA-II reduzido a uma solução de compromisso (Seção 5).

Método	Dist. média (km)	Cobertura ≤ 80 km (%)	P95 (km)	Desv. cobertura	Tempo (s)
AG baseline (gen=300)	39,74 $\pm$ 0,49	84,98 $\pm$ 2,97	109,91 $\pm$ 5,41	2,97%	4,61
AG single-obj. V3 (gen=500)	39,44 $\pm$ 0,60	85,51 $\pm$ 2,49	108,87 $\pm$ 3,68	2,49%	7,63
NSGA-II (compromisso)	40,34 $\pm$ 0,50	90,40 $\pm$ 0,33	97,90 $\pm$ 4,22	0,33%	7,96

O NSGA-II entrega +4,89 p.p. de cobertura e -10,97 km de P95 frente ao melhor AG single-objective, ao custo de apenas +0,90 km na distância média — e é $\approx 9\times$ mais estável (desvio da cobertura). Em compensação, abre mão da melhor solução de pico isolada em f_1 : o melhor ponto do front NSGA-II chega a $\approx 38,10$ km (não uma solução única), enquanto o AG V3 atinge 38,62 km como solução única, e o baseline já alcança 39,02 km de forma mais rápida e simples.

A fronteira de Pareto agregada (5 sementes) contém entre 10 e 28 soluções não-dominadas por execução, cobrindo f_1 de $\approx 38,1$ a 52,0 km, cobertura de $\approx 83\%$ a 92,8% e P95 de $\approx 88,1$ a 107,4 km. A visualização gráfica (fig8_frenteira_pareto.png) ainda não foi anexada — recomenda-se incluí-la na versão final.

5. Discussão de Trade-offs e Equidade Espacial

- **Eficiência $\times$ cobertura $\times$ equidade:** minimizar apenas a distância média privilegia regiões populosas e centrais; municípios periféricos (>80 km) têm peso pequeno na média e tendem a ser ignorados pelo single-objective. O NSGA-II torna esse custo explícito ao tratar cobertura e equidade como objetivos independentes.
- **Trade-offs na fronteira:** distância $\times$ cobertura — soluções mais dispersas ampliam a cobertura ao custo de leve aumento na média (fronteira em degraus); distância $\times$ P95 — reduzir o P95 exige aceitar um pequeno aumento na média, pois a cauda da distribuição penaliza desproporcionalmente municípios muito distantes; cobertura $\times$ P95 — correlação negativa, mas as métricas são apenas parcialmente redundantes (nenhuma domina completamente a outra).
- **Restrição orçamentária:** penalização (AG single-objective) é simples, mas exige calibrar λ ; dominância restrita (NSGA-II) dispensa esse parâmetro e garante front 100% viável, como confirmado experimentalmente.
- **Estabilidade vs. pico:** o NSGA-II é o método mais robusto entre execuções, mas o single-objective é mais competitivo quando o critério é o melhor valor isolado de um único objetivo, aceitando variabilidade entre sementes.

- **Custo computacional:** tempos comparáveis ($\approx 7,6$ – $8,0$ s); pelo mesmo custo, o NSGA-II devolve um conjunto de 10–28 alternativas, em vez de uma única solução, permitindo ao tomador de decisão escolher o ponto da fronteira mais alinhado a suas prioridades sem reexecutar o algoritmo.
- **Solução de compromisso:** usada apenas para viabilizar a comparação numérica (menor norma L2 após normalizar os três objetivos), ela dá peso igual a eficiência, cobertura e equidade — um julgamento de valor implícito. A fronteira de Pareto preserva essa escolha em aberto, o que é desejável: a decisão final é de natureza política e deveria ser tomada com informação completa sobre os custos de cada alternativa, e não fixada de antemão pela equipe técnica.
- **Equidade como diferencial ético:** o ganho de quase 5 pontos percentuais de cobertura e quase 11 km de redução no P95, ao custo de menos de 1 km na distância média, sustenta o argumento de que a equidade espacial deveria ser tratada como objetivo de primeira classe na modelagem — não relegada a uma restrição ou a uma análise posterior.

6. Conclusão

O projeto resolveu o problema de localização de facilidades em Goiás em duas versões — single-objective (AG binário com penalização orçamentária) e multiobjetivo (NSGA-II com dominância restrita). Embora o AG single-objective encontre a menor distância média isolada, o NSGA-II entrega soluções mais equilibradas entre eficiência, cobertura e equidade, e muito mais estáveis entre execuções, a custo computacional comparável e com pequeno acréscimo na distância média.

O resultado central é que a formulação multiobjetivo não é apenas uma generalização técnica do single-objective: ela muda qualitativamente como o trade-off entre eficiência e equidade é tratado, expondo-o explicitamente na fronteira de Pareto em vez de resolvê-lo implicitamente — e de forma enviesada a favor das regiões mais populosas — dentro de uma única função escalar.

6.1 Limitações e Próximos Passos

- incluir a figura da fronteira de Pareto (fig8_frenteira_pareto.png) com as projeções 2D entre f_1 , f_2 e f_3 ;
- consolidar os resultados numéricos do índice de Gini (Christian) e compará-los com a métrica de P95 usada no NSGA-II;
- detalhar o código do NSGA-II na mesma profundidade dada ao AG single-objective;
- merge final das branches modelagem-completa e versao-multiobjetivo na branch pre-final, seguido da entrega do PDF deste relatório.

7. Referências

DEB, K. et al. A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, v. 6, n. 2, p. 182–197, 2002.

TALBI, E.-G. *Metaheuristics: From Design to Implementation*. Hoboken: Wiley, 2009.

DEB, K. *Multi-Objective Optimization Using Evolutionary Algorithms*. Chichester: Wiley, 2001.

IBGE. *Censo Demográfico 2022*. Instituto Brasileiro de Geografia e Estatística, 2022.

IMB. *Base de dados estatísticos e geográficos do Estado de Goiás*. Instituto Mauro Borges de Estatísticas e Estudos Socioeconômicos.